

統計学 第3章・第6章 演習 復習ノート

作成日: 2026-09-22 / 対象: 添付画像「統計学3章演習」「統計学6章演習」から読める演習 / 注意: 問題文は長く転載せず、問題番号・テーマ・必要な数値だけを整理しています。

今日のテーマ

- 第3章: 推定量、不偏性、一致性、最尤推定、フィッシャー情報量、デルタ法
- 第6章: 重回帰分析、主成分分析、回帰直線、ポアソン分布の適合度検定

まず一言で

第3章は「推定量がよい推定量か」を期待値・分散・情報量で確認する章です。

第6章は「複数の変数をまとめて見る」章で、回帰は予測や説明、主成分分析は多変量データの要約、適合度検定はデータが想定分布に合うかを見る方法です。

理解に必要な前提

- 期待値と分散: 推定量の平均的な位置とばらつきを見る。
- 対数尤度: 積で表される尤度を和にして、微分しやすくする。
- 相関と回帰: 変数どうしの直線的な関係と、予測式の意味を分ける。
- カイ二乗分布: 度数データの「観測値と期待値のずれ」を評価する。

第3章：推定量と最尤推定

問3.1 変換 $Y = \log(1+X)$ と推定量 T

問題単位で、式・読み方・解釈を分けて確認します。

問題の整理

確率密度関数が

$$f(x; \theta) = \theta (1+x)^{-(1+\theta)}, \quad \theta > 0, x > 0$$

である母集団から、独立同分布標本 $X_1, \dots, X_n$ を取る。

$Y = \log(1+X)$ と変換し、 $T = (1/n) \sum \log(1+X_i)$ を考える。

(1) Y の密度、平均、分散

変換は

$$\begin{aligned} y &= \log(1+x) \\ x &= e^y - 1 \\ dx/dy &= e^y \end{aligned}$$

なので、変数変換の公式より

$$\begin{aligned} g(y) &= f(e^y - 1; \theta) * e^y \\ &= \theta (e^y)^{-(1+\theta)} * e^y \\ &= \theta e^{-(\theta+1)y}, \quad y > 0 \end{aligned}$$

つまり Y はパラメータ θ の指数分布に従う。

指数分布 $\text{Exp}(\theta)$ の平均と分散は

$$\begin{aligned} E[Y] &= 1/\theta \\ \text{Var}(Y) &= 1/\theta^2 \end{aligned}$$

である。

(2) T が $1/\theta$ の一致推定量であること

T は $Y_i = \log(1+X_i)$ の標本平均である。

$$T = (Y_1 + \dots + Y_n) / n$$

Y_i は平均 $1/\theta$ 、分散 $1/\theta^2$ の独立同分布なので、大数の法則より

$$T \rightarrow E[Y] = 1/\theta$$

となる。したがって T は $1/\theta$ の一致推定量である。

(3) T が不偏推定量で、分散がクラメル＝ラオ下限に一致すること

不偏性は期待値を取ればよい。

$$\begin{aligned} E[T] &= E[(Y_1 + \dots + Y_n)/n] \\ &= (1/n)(E[Y_1] + \dots + E[Y_n]) \\ &= 1/\theta \end{aligned}$$

よって T は $1/\theta$ の不偏推定量である。

分散は独立性より

$$\begin{aligned}\text{Var}(T) &= \text{Var}((Y_1 + \dots + Y_n)/n) \\ &= (1/n^2) * n * \text{Var}(Y) \\ &= 1/(n \theta^2)\end{aligned}$$

次に、 $1/\theta$ を推定する不偏推定量のクラメール＝ラオ下限を確認する。

1標本の対数尤度は

$$\log f(x; \theta) = \log \theta - (1+\theta) \log(1+x)$$

微分すると

$$\begin{aligned}d/d\theta \log f(x; \theta) &= 1/\theta - \log(1+x) \\ d^2/d\theta^2 \log f(x; \theta) &= -1/\theta^2\end{aligned}$$

1標本のフィッシャー情報量は

$$I(\theta) = -E[d^2/d\theta^2 \log f(X; \theta)] = 1/\theta^2$$

n 標本では

$$I_n(\theta) = n/\theta^2$$

推定したい量を $\tau(\theta) = 1/\theta$ とおくと

$$\tau'(\theta) = -1/\theta^2$$

クラメール＝ラオ下限は

$$\begin{aligned}\{\tau'(\theta)\}^2 / I_n(\theta) \\ &= (1/\theta^4) / (n/\theta^2) \\ &= 1/(n \theta^2)\end{aligned}$$

これは $\text{Var}(T)$ と一致する。

つまり T はこの意味で効率的な不偏推定量である。

よくある間違い

- X の分布のまま平均を直接出そうとして計算が重くなる。
- $Y = \log(1+X)$ と置いた後のヤコビアン $dx/dy = e^y$ を忘れる。
- 一致性と不偏性を同じものとして扱う。

問3.2 指数分布の最尤推定とデルタ法

問題単位で、式・読み方・解釈を分けて確認します。

問題の整理

$X_1, \dots, X_n$ は指数分布

$$f(x) = \lambda e^{-(\lambda x)}, \quad x \geq 0$$

に従う。 $T = X_1 + \dots + X_n$ 、標本平均を $\bar{X} = T/n$ とする。

(1) 標本平均の期待値と分散

指数分布の平均と分散は

$$\begin{aligned} E[X] &= 1/\lambda \\ \text{Var}(X) &= 1/\lambda^2 \end{aligned}$$

したがって

$$\begin{aligned} E[\bar{X}] &= 1/\lambda \\ \text{Var}(\bar{X}) &= 1/(n \lambda^2) \end{aligned}$$

(2) λ の最尤推定量

尤度は

$$\begin{aligned} L(\lambda) &= \text{product } \lambda e^{-\lambda x_i} \\ &= \lambda^n e^{-\lambda t} \end{aligned}$$

対数尤度は

$$\ell(\lambda) = n \log \lambda - \lambda t$$

微分して0とおく。

$$d \ell / d \lambda = n/\lambda - t = 0$$

よって

$$\hat{\lambda} = n/t = 1/\bar{X}$$

(3) n 標本のフィッシャー情報量

1標本の対数尤度は

$$\log f(x; \lambda) = \log \lambda - \lambda x$$

2階微分は

$$d^2/d\lambda^2 \log f(x; \lambda) = -1/\lambda^2$$

したがって

$$i_n(\lambda) = n/\lambda^2$$

(4) デルタ法で $\hat{\lambda}$ の漸近分散を求める

標本平均について

$$\bar{X} \text{ approximately } N(1/\lambda, 1/(n \lambda^2))$$

$\hat{\lambda} = 1/\bar{X}$ は、関数 $g(x) = 1/x$ を $\bar{X}$ に適用したもの。

デルタ法より

$$\text{Var}(g(\bar{X})) \text{ approximately } \{g'(1/\lambda)\}^2 \text{Var}(\bar{X})$$

ここで

$$\begin{aligned} g'(x) &= -1/x^2 \\ g'(1/\lambda) &= -\lambda^2 \end{aligned}$$

よって

$$\begin{aligned} \text{Var}(\lambda_{\text{hat}}) &\text{approximately } \lambda^4 * 1/(n \lambda^2) \\ &= \lambda^2/n \end{aligned}$$

最尤推定量の標準誤差は、おおよそ $\lambda / \sqrt{n}$ と見ればよい。

第6章：多変量解析と検定

問6.1 重回帰分析

問題単位で、式・読み方・解釈を分けて確認します。

問題の整理

入学時の英語テスト Listening と Reading を説明変数、期末試験の点数 Y を目的変数として、重回帰モデル

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \epsilon_i$$

を考える。

(1) 重回帰モデルの通常の仮定

代表的な仮定は次の通り。

- $E[\epsilon_i] = 0$: 誤差の平均は0
- $\text{Var}(\epsilon_i) = \sigma^2$: 誤差分散は一定
- $\text{Cov}(\epsilon_i, \epsilon_j) = 0$: 異なる観測の誤差は無相関
- 説明変数と誤差は独立、または少なくとも無相関
- 推測を行うときは誤差の正規性を仮定することが多い
- 強い多重共線性がないことが望ましい

(2) 重回帰出力の読み方

画像から読める主な出力は次の通り。

重相関係数 $R = 0.793$
決定係数 $R^2 = 0.629$
自由度調整済み $R^2 = 0.523$
 $F = 5.926, P = 0.031$

意味は次のように読む。

- $R = 0.793$: 実測値 Y とモデルの予測値の相関がかなり高い。
- $R^2 = 0.629$: Y のばらつきの約62.9%を、Listening と Reading で説明している。
- 自由度調整済み $R^2 = 0.523$: 説明変数の個数を考慮すると説明力は約52.3%程度。
- F 検定の $P = 0.031$: 「すべての回帰係数が0」という帰無仮説は5%水準で棄却される。

係数はおおよそ

$$\hat{Y} = -1.938 + 0.099 \text{ Listening} + 0.194 \text{ Reading}$$

ただし Listening の P 値は 0.457、Reading の P 値は 0.141 であり、個別には5%水準で有意とはいえない。

重要な解釈

全体としてはモデルに説明力があるが、Listening と Reading は互いに相関が高いため、重回帰に同時投入すると個々の係数の有意性が弱く見える。

これが多重共線性の典型的な見え方である。

(3) Listening のみ、Reading のみ、Total のみを説明変数にした場合

画像から読める単回帰の結果は次の通り。

説明変数	係数	P値	決定係数
---	---	---	---
Listening のみ	0.254	0.026	0.418
Reading のみ	0.262	0.009	0.545
Total のみ	0.148	0.007	0.572

3つとも単回帰では有意で、特に Total がもっとも決定係数が高い。

(4) Listening・Reading・Total を同時に使うべきか

Total は Listening + Reading で作られているため、3つを同時に入れると説明変数どうしが完全に線形従属になる。

そのため、通常の重回帰では同時投入すべきではない。

今回のデータでは、実用上は Total の単回帰が簡単で説明力も高い。

Listening と Reading を分けて考察したい目的がある場合のみ、2変数の重回帰を使うとよい。

問6.2 主成分分析

問題単位で、式・読み方・解釈を分けて確認します。

問題の整理

5教科の得点、平均、標準偏差、相関行列、主成分分析の結果が与えられている。

変数は国語、社会、数学、理科、英語である。

(1) 記述統計量と相関行列の読み方

平均と標準偏差から、科目ごとの点数水準とばらつきが見える。

科目	平均	標準偏差
---	---	---
国語	58.400	13.810
社会	48.917	9.772
数学	44.033	13.769
理科	49.283	7.514
英語	50.508	7.503

相関行列からは次が読み取れる。

- 国語と社会: 0.840 と非常に高い。
- 数学と理科: 0.819 と非常に高い。
- 英語は国語・社会ともある程度相関がある。
- 国語と数学の相関は 0.206 と低め。

つまり「文系寄りの科目群」と「理系寄りの科目群」が見えやすいデータである。

(2) 主成分分析とは

主成分分析は、複数の変数を少数の合成変数にまとめる方法である。

相関行列を使う場合、各主成分は標準化された変数の線形結合として作られる。

第1主成分 = a_1 国語 + a_2 社会 + a_3 数学 + a_4 理科 + a_5 英語

固有値は、その主成分が持つ分散の大きさを表す。

寄与率は「全体の情報のうち、その主成分が何割を説明するか」である。

(3) 固有値・寄与率の解釈

画像から読める結果は次の通り。

| 主成分 | 固有値 | 寄与率 | 累積寄与率 |

| --- | --- | --- | --- |

| 第1 | 3.030 | 0.606 | 0.606 |

| 第2 | 1.219 | 0.244 | 0.850 |

| 第3 | 0.431 | 0.086 | 0.936 |

| 第4 | 0.178 | 0.036 | 0.971 |

| 第5 | 0.143 | 0.029 | 1.000 |

第1主成分だけで約60.6%、第2主成分までで約85.0%を説明する。

したがって、2次元に要約してもかなり多くの情報を保てる。

(4) 固有ベクトルと主成分負荷量の解釈

第1主成分の係数は全科目で正で、だいたい同じ大きさである。

第1主成分: 0.436 国語 + 0.487 社会 + 0.411 数学 + 0.435 理科 + 0.464 英語

これは「総合学力」を表す軸と解釈できる。

全体的に点数が高い生徒ほど、第1主成分得点が高くなる。

第2主成分は、国語・社会が正、数学・理科が負になっている。

第2主成分: 0.515 国語 + 0.364 社会 - 0.571 数学 - 0.512 理科 + 0.120 英語

これは「文系寄りか理系寄りか」を表す軸と解釈できる。

第2主成分が高いほど文系科目寄り、低いほど理系科目寄りと読める。

よくある間違い

- 固有値を「点数」と勘違いする。固有値は主成分の分散である。
- 寄与率だけ見て、主成分の意味を解釈しない。
- 主成分の符号に絶対的な意味を持たせる。主成分は全体の符号を反転しても同じ軸を表す。

問6.3 3組の回帰直線

問題単位で、式・読み方・解釈を分けて確認します。

問題の整理

同じ $x = 0, 1, 2, 3, 4$ に対して、3種類の y が与えられている。

与えられた要約量は以下。

```
xbar = 2.0, Ax = 10.0
ybar(1)=1.1, Ay(1)=3.7, Axy(1)=5.0
ybar(2)=2.1, Ay(2)=11.2, Axy(2)=10.0
ybar(3)=4.1, Ay(3)=41.2, Axy(3)=20.0
```

ここで

```
Ax = sum (xi - xbar)^2
Ay = sum (yi - ybar)^2
Axy = sum (xi - xbar)(yi - ybar)
```

である。

(1) 回帰直線を求める

単回帰直線は

```
yhat = a + b x
b = Axy / Ax
a = ybar - b xbar
```

よって

データ	b	a	回帰直線
y(1)	0.5	0.1	yhat = 0.1 + 0.5x
y(2)	1.0	0.1	yhat = 0.1 + 1.0x
y(3)	2.0	0.1	yhat = 0.1 + 2.0x

(2) 散布図の読み方

3組とも直線の傾きは異なるが、切片はいずれも 0.1 である。

図を描くと、y(1) はゆるやか、y(2) は中くらい、y(3) は急な右上がりになる。

(3) 決定係数を求める

単回帰の決定係数は

```
R^2 = Axy^2 / (Ax Ay)
```

したがって

```
R^2(1) = 5^2 / (10 * 3.7) = 25/37 = 0.676
R^2(2) = 10^2 / (10 * 11.2) = 100/112 = 0.893
R^2(3) = 20^2 / (10 * 41.2) = 400/412 = 0.971
```

y(3) がもっとも直線によく乗っている。

(4) 残差分散の推定値

残差平方和は

$$SSE = A_y - b A_{xy}$$

である。

$$\begin{aligned} SSE(1) &= 3.7 - 0.5 * 5 = 1.2 \\ SSE(2) &= 11.2 - 1.0 * 10 = 1.2 \\ SSE(3) &= 41.2 - 2.0 * 20 = 1.2 \end{aligned}$$

単回帰では切片と傾きの2つを推定するので、自由度は $n-2 = 3$ 。

したがって残差分散の推定値は

$$s^2 = 1.2 / 3 = 0.4$$

3組すべてで同じになる。

(5) $y(2)$ の回帰直線の信頼区間

$y(2)$ では

$$\begin{aligned} \hat{y} &= 0.1 + 1.0x \\ s^2 &= 0.4 \\ n &= 5 \\ \bar{x} &= 2 \\ A_x &= 10 \end{aligned}$$

平均応答 $m_0 = a + b x_0$ の95%信頼区間は、おおよそ

$$m_0 \pm t_{(0.975, 3)} * s * \sqrt{1/n + (x_0 - \bar{x})^2 / A_x}$$

である。

ここで $t_{(0.975, 3)}$ は自由度3の t 分布の上側2.5%点で、約3.182である。

注意点: これは「平均的な直線の位置」の信頼区間であり、個々の新しい観測値の予測区間より狭い。

問6.4 ポアソン分布の適合度検定

問題単位で、式・読み方・解釈を分けて確認します。

問題の整理

ワールドカップの試合ごとのゴール数について、度数表が与えられている。

読める度数は次の通り。

ゴール数	0	1	2	3	4	5	6	7	合計
度数	35	35	18	5	2	0	0	1	96

(1) なぜポアソン分布を仮定するのか

ゴール数は「一定時間内に何回イベントが起きるか」を数えるデータである。

各試合でゴールが独立に、平均的な発生率に従って起きると近似できるなら、ポアソン分布を候補にできる。

ただし現実にはチーム力、戦術、延長の有無などの影響があるため、完全な仮定ではなく近似モデルである。

(2) lambda の推定

ポアソン分布の平均は λ なので、標本平均で推定する。

```
lambda_hat = 合計ゴール数 / 試合数
             = 101 / 96
             = 1.052
```

(3) 期待度数とセルの結合

$\lambda_{\text{hat}} = 1.052$ として期待度数を計算すると、おおよそ次のようになる。

ゴール数	観測度数	期待度数
0	35	33.524
1	35	35.270
2	18	18.554
3	5	6.507
4以上	3	2.146

画像の解答では、4以上をまとめた形でカイ二乗統計量が計算されていると読める。

(4) 適合度検定

検定統計量は

```
X^2 = sum (観測度数 - 期待度数)^2 / 期待度数
```

上の区分では

```
X^2 = 0.773 付近
```

となる。

パラメータ λ をデータから1つ推定しているので、自由度は

```
自由度 = セル数 - 1 - 推定パラメータ数
        = 5 - 1 - 1
        = 3
```

画像の解答では P値は約 0.856 と読める。

P値が十分大きいため、ポアソン分布に従うという仮定を棄却する根拠はない。

よくある間違い

- λ を既知として扱い、自由度を1つ多くしてしまう。
- 期待度数が小さいセルをそのまま細かく分けすぎる。
- 「棄却できない」を「ポアソン分布であると証明できた」と言い換えてしまう。

小さな確認問題

1. 問3.1で、 $Y = \log(1+X)$ と置いたときに dx/dy を忘れると、密度はどこでおかしくなるか。
2. 問3.2で、 $\lambda_{\text{hat}} = 1/\bar{X}$ は不偏推定量か。直感的にはなぜ注意が必要か。
3. 問6.1で、単回帰では有意なのに重回帰で個別係数が有意でない理由を一言で説明せよ。
4. 問6.2で、第1主成分と第2主成分はそれぞれ何を表すと解釈できるか。
5. 問6.4で、適合度検定の自由度から「推定したパラメータ数」を引く理由を説明せよ。

次にやること

- 第3章は「不偏性」「一致性」「効率性」の違いを1枚にまとめる。
- 第6章は「回帰」「主成分分析」「適合度検定」を、目的別に使い分けられるようにする。
- 手計算練習として、問6.3の回帰係数と決定係数をもう一度自力で計算する。

参考リンク

- 総務省統計局 データサイエンス・スクール：重回帰、残差分散、自由度調整済み決定係数の考え方

<https://www.stat.go.jp/dss/getting/pdf/upper.pdf>

- 統計WEB：決定係数と重相関係数

<https://bellcurve.jp/statistics/course/9706.html>

- 慶應義塾大学教材：主成分分析の固有値・固有ベクトル・寄与率

<https://www.math.keio.ac.jp/~kei/GDS/2nd/pca.html>

- 適合度検定の解説

<https://herolog.jp/statistics/goodness-of-fit-test.php>