

# 統計学3章 演習解説ノート

作成日: 2026-09-23

## このPDFの使い方

添付画像に写っている3章の演習を、推定量の性質が見えるように解説した復習ノートです。問題文そのものの転記ではなく、読み取れた内容をもとに「どの式を使うか」「なぜその式になるか」を中心に整理しています。

## まず押さえる前提

- 一致性: 標本サイズ  $n$  を大きくすると、推定量が推定したい値に近づく性質です。
- 不偏性: 推定量の期待値が、推定したい値そのものになる性質です。
- フィッシャー情報量: パラメータを少し動かしたとき、分布がどれだけ敏感に変わるかを表す量です。
- クラメール-ラオ下限: 不偏推定量の分散がこれより小さくならない、という理論上の下限です。
- デルタ法: 推定量を関数で変換したときの近似分散を、微分で求める方法です。

## 問3.1: 変数変換で指数分布に直す

確率密度が  $f(x; \theta) = \theta(1+x)^{-(1+\theta)}$ ,  $x > 0$  の母集団から標本を取る設定です。ここで  $Y = \log(1+X)$  とおくと、難しそうな密度が指数分布になります。

### 変数変換

$y = \log(1+x)$  なので、逆変換は  $x = \exp(y)-1$ 、微分は  $dx/dy = \exp(y)$  です。したがって

$$g(y) = f(\exp(y)-1; \theta) * \exp(y) = \theta \exp(-\theta y), y > 0$$

となり、 $Y$  は率パラメータ  $\theta$  の指数分布に従います。

### 平均と分散

$Y$  が指数分布  $\text{Exp}(\theta)$  なら、

- $E[Y] = 1/\theta$
- $\text{Var}(Y) = 1/\theta^2$

です。 $X$  の形で考えるより、 $Y$  に直してから指数分布の公式を使うのが近道です。

### $T$ が $1/\theta$ の一致推定量である理由

$T = (1/n) \sum \log(1+X_i)$  は、変換後の  $Y_i$  の標本平均です。大数の法則より、標本平均は母平均に近づきます。

$$T = \bar{Y} \rightarrow E[Y] = 1/\theta$$

したがって  $T$  は  $1/\theta$  の一致推定量です。

### $T$ が不偏推定量である理由

期待値の線形性を使うと、

$$E[T] = E[(1/n) \sum Y_i] = (1/n) \sum E[Y_i] = 1/\theta$$

となります。よって  $T$  は  $1/\theta$  の不偏推定量です。

## T の分散とクラメール-ラオ下限

独立な標本平均なので、

$$\text{Var}(T) = \text{Var}(\bar{Y}) = \text{Var}(Y)/n = 1/(n \theta^2)$$

一方、1標本あたりの対数尤度は  $\log \theta - \theta y$  なので、 $\theta$  に関する情報量は  $I_1(\theta)=1/\theta^2$ 、 $n$  標本では  $I_n(\theta)=n/\theta^2$  です。

推定対象を  $\tau(\theta)=1/\theta$  とすると、 $\tau'(\theta)=-1/\theta^2$  です。クラメール-ラオ下限は

$$[\tau'(\theta)]^2 / I_n(\theta) = (1/\theta^4)/(n/\theta^2) = 1/(n \theta^2)$$

となり、 $T$  の分散と一致します。つまり  $T$  は、この設定では分散の意味でかなり良い不偏推定量です。

## 問3.2: 指数分布の最尤推定とデルタ法

率パラメータ  $\lambda$  の指数分布  $f(x)=\lambda \exp(-\lambda x)$ ,  $x \geq 0$  から独立に  $n$  個観測する設定です。

### 標本平均の期待値と分散

指数分布では  $E[X]=1/\lambda$ ,  $\text{Var}(X)=1/\lambda^2$  なので、

- $E[\bar{X}] = 1/\lambda$
- $\text{Var}(\bar{X}) = 1/(n \lambda^2)$

です。

### $\lambda$ の最尤推定量

観測値の和を  $t = x_1 + \dots + x_n$  とすると、尤度は

$$L(\lambda) = \lambda^n \exp(-\lambda t)$$

対数尤度は

$$\ell(\lambda) = n \log \lambda - \lambda t$$

です。微分して0にすると、

$$n/\lambda - t = 0$$

より、

$$\hat{\lambda} = n/t = 1/\bar{X}$$

です。

### フィッシャー情報量

2階微分は  $\ell''(\lambda) = -n/\lambda^2$  です。よって

$$I_n(\lambda) = -E[\ell''(\lambda)] = n/\lambda^2$$

です。

### デルタ法による $\hat{\lambda}$ の漸近分散

$\hat{\lambda} = g(\bar{X})$ 、 $g(u)=1/u$  と見ます。 $\bar{X}$  は平均  $1/\lambda$ 、分散  $1/(n \lambda^2)$  をもちます。

$g'(u) = -1/u^2$  なので、 $u=1/\lambda$  では  $g'(1/\lambda)=-\lambda^2$  です。

したがって

$$\text{Var}(\hat{\lambda}) \approx [g'(1/\lambda)]^2 \text{Var}(\bar{X}) = \lambda^4 * 1/(n \lambda^2) = \lambda^2/n$$

となります。

## つまずきやすい点

- 「一致」と「不偏」は別物です。不偏は平均として正しいこと、一致は  $n$  を増やしたとき近づくことです。
- $X$  のまま悩まず、 $Y = \log(1+X)$  に直すと指数分布になります。
- クラメール-ラオ下限で推定対象が  $\theta$  ではなく  $1/\theta$  のときは、 $\tau'(\theta)$  を必ず入れます。
- デルタ法では、関数そのものではなく、その点での微分が近似分散に効きます。

## 確認問題

- 1.  $Y \sim \text{Exp}(\theta)$  のとき、 $n\bar{Y}$  ではなく  $\bar{Y}$  が推定している量は何か。
- 2.  $\lambda_{\text{hat}} = 1/\bar{X}$  は、なぜ  $\lambda$  の直感的な推定量といえるか。
- 3. クラメール-ラオ下限で  $\tau(\theta) = 1/\theta$  と置いたとき、 $\tau'(\theta)$  は何か。

## 参考リンク

- Cramér-Rao bound: [https://en.wikipedia.org/wiki/Cram%C3%A9r%E2%80%93Rao\\_bound](https://en.wikipedia.org/wiki/Cram%C3%A9r%E2%80%93Rao_bound)
- Fisher information: [https://en.wikipedia.org/wiki/Fisher\\_information](https://en.wikipedia.org/wiki/Fisher_information)
- Exponential distribution: [https://en.wikipedia.org/wiki/Exponential\\_distribution](https://en.wikipedia.org/wiki/Exponential_distribution)