

統計学6章 演習解説ノート

作成日：2026-09-23

このPDFの使い方

添付画像に写っている6章の演習を、分析結果の読み方に重点を置いて解説した復習ノートです。重回帰分析、変数選択、主成分分析、単回帰、ポアソン近似が含まれます。

6章の全体像

6章は「複数の変数から、目的変数やデータ全体の構造を説明する」章です。中心になる発想は次の3つです。

- ・ 回帰分析： y を x で説明・予測する。
- ・ 変数選択：説明に役立つ変数を残し、弱い変数を外す。
- ・ 主成分分析：複数の変数を、情報をよく保つ少数の軸にまとめる。

問6.1：英語テスト点数の重回帰分析

目的変数 y は期末試験の点数、説明変数は Listening と Reading です。モデルは

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i$$

です。

通常置かれる仮定

重回帰モデルでは、典型的に次の仮定を置きます。

- ・ 誤差の平均は0: $E[\varepsilon_i] = 0$
- ・ 誤差の分散は一定: $\text{Var}(\varepsilon_i) = \sigma^2$
- ・ 異なる観測の誤差は無相関または独立
- ・ 説明変数と誤差は無相関
- ・ 推測を行うときは、誤差の正規性を仮定することが多い
- ・ 強い多重共線性がない

回帰出力の読み方

読み取れた出力では、重相関係数は 0.793、決定係数は 0.629、自由度調整済み決定係数は 0.523 です。

指標	値	意味
重相関係数	0.793	実測値と予測値の相関が比較的高い
決定係数	0.629	y のばらつきの約62.9%をモデルが説明
調整済み決定係数	0.523	説明変数の数を考慮すると説明力は約52.3%

ANOVA表では $F=5.926$, $P=0.031$ です。5%水準なら、モデル全体は「説明力が全くない」とは言いにくい、つまり有意と見ます。

係数表はおおよそ次の形です。

係数	推定値	標準誤差	t値	P値
切片	-1.938	21.502	-0.090	0.931
Listening	0.099	0.126	0.786	0.457
Reading	0.194	0.117	1.660	0.141

したがって推定式は

$$\hat{y} = -1.938 + 0.099 \text{ Listening} + 0.194 \text{ Reading}$$

です。Reading の係数は Listening より大きいですが、どちらのP値も5%水準では有意ではありません。サンプルが10人と少ないため、個別係数の不確実性が大きい点に注意します。

変数選択の見方

画像の続きでは、Listening のみ、Reading のみ、Total のみを説明変数にした単回帰の結果も示されています。

変数	係数	P値	決定係数	調整済み決定係数
Listeningのみ	0.254	0.026	0.483	0.418
Readingのみ	0.262	0.009	0.596	0.545
Totalのみ	0.148	0.007	0.619	0.572

単回帰では Total の調整済み決定係数が最大です。ただし Total は Listening と Reading の和なので、解釈としては「総合点が高い学生ほど期末点も高い」と読むのが自然です。

問6.2: 5科目の主成分分析

国語・社会・数学・理科・英語の5科目について、標準化したデータで主成分分析を行う設定です。標準化するのは、科目ごとの単位やばらつきの差に引っ張られないようにするためです。

相関行列から何を見るか

相関行列では、社会と国語の相関が 0.840、数学と理科の相関が 0.819 と高くなっています。これは、文系寄りのまとまりと理系寄りのまとまりがありそうだ、という予想につながります。

固有値と寄与率

主成分分析表では、固有値と累積寄与率がおおよそ次のようになっています。

主成分	固有値	寄与率	累積寄与率
第1主成分	3.030	0.606	0.606
第2主成分	1.219	0.244	0.850
第3主成分	0.431	0.086	0.936
第4主成分	0.178	0.036	0.971
第5主成分	0.143	0.029	1.000

第1主成分だけで約60.6%、第2主成分までで約85.0%の情報を説明します。したがって、2次元でかなり要約できるデータです。

主成分ベクトルの解釈

第1主成分の係数はすべて正で、各科目に比較的同じ向きに重みがかかっています。したがって第1主成分は「総合学力」と解釈できます。

第2主成分は、国語・社会・英語が正、数学・理科が負です。したがって第2主成分は「文系寄りか理系寄りか」を表す軸と解釈できます。符号は反転しても本質は同じなので、正負そのものより、どの科目群が同じ側にあるかを見ます。

因子負荷量

因子負荷量は、主成分と元の変数の相関のように読めます。第1因子では多くの科目が大きく正なので総合力、第2因子では文系科目と理系科目が反対方向に分かれる、と読みます。

問6.3: 3本の回帰直線と信頼区間

x の値 $\{0, 1, 2, 3, 4\}$ に対して、3種類の y が観測された設定です。

回帰直線

読み取れる回帰式は次の通りです。

$$\bullet \hat{y}_1 = -0.5 + 0.5x$$

$$\bullet \hat{y}_2 = 0.1 + 1.0x$$

$$\bullet \hat{y}_3 = 0.1 + 2.0x$$

傾きはそれぞれ 0.5、1.0、2.0 です。傾きが大きいほど、 x が1増えたとき y が大きく変わります。

決定係数と残差分散

残差平方和が同じでも、 y 自体のばらつきが大きいほど、回帰で説明できた割合である決定係数は大きくなります。つまり、同じ誤差の大きさでも、データ全体のスケールが違えば R^2 の印象は変わります。

信頼区間は、平均的な回帰直線の不確実性を表します。予測区間は、新しい1点のばらつきも含むので、信頼区間より広がります。

問6.4: ポアソン分布と正規近似

サッカーのゴール数をポアソン分布で近似する設定です。度数は 0点:35試合、1点:35試合、2点:18試合、3点:5試合、4点:2試合、5点:0試合、6点:0試合、7点:1試合、合計96試合です。

ポアソン分布を使う理由

ゴール数は0, 1, 2, ... というカウントデータです。一定時間内にまれな出来事が何回起こるかを表すモデルとして、ポアソン分布がよく使われます。

平均と推定値

標本平均は

$$\bar{x} = 101/96 \approx 1.052$$

です。ポアソン分布では平均と分散がどちらも λ なので、最尤推定値も $\hat{\lambda} = 1.052$ です。

適合度の読み方

適合度検定では、観測度数と期待度数のずれを合計してカイ二乗統計量を作ります。画像の解答では検定統計量が約 0.774、P値が 0.856 と読み取れます。P値が大きいので、このデータにポアソン分布が合わないとはいえません。

λ の95%信頼区間

正規近似を使うと、信頼区間はおおよそ

$$1.052 \pm 0.205 = (0.847, 1.257)$$

スコア型の近似では

$$(0.863, 1.283)$$

のようになります。どちらも「1試合あたり平均1点前後」という見方を支えています。

よくある誤解

- ・ 決定係数が高いことは、因果関係を証明することではありません。
- ・ P値が大きいことは「効果がゼロである証明」ではありません。サンプルが少ないと検出力が弱くなります。
- ・ 主成分の符号は任意です。第2主成分の正負が逆になっても、解釈は同じです。
- ・ 信頼区間と予測区間は別物です。予測区間のほうが広がります。
- ・ ポアソン分布は「平均=分散」が強い仮定です。実データで分散が極端に大きいときは注意します。

確認問題

1. 問6.1で、モデル全体のF検定が有意でも、個別係数が有意でないことがあるのはなぜか。
2. 問6.2で、第1主成分の係数がすべて正のとき、どんな軸と解釈しやすいか。
3. 問6.3で、信頼区間より予測区間が広い理由は何か。
4. 問6.4で、ポアソン分布の平均と分散の関係は何か。

参考リンク

- ・ OLS regression assumptions and interpretation: <https://www.coursera.org/articles/ols-regression>
- ・ Regression equation and OLS assumptions: https://stats.libretexts.org/Bookshelves/Introductory_Statistics/Introductory_Statistics_2e_%28OpenStax%29/13%3A_Linear_Regression_and_Correlation/13.05%3A_The_Regression_Equation
- ・ Principal Components Analysis, Penn State STAT 505: <https://online.stat.psu.edu/stat505/Lesson11>