

統計学2章 本文網羅ノート

章全体の見取り図

2章は「確率分布を道具として使えるようにする章」です。写真で確認できた範囲では、離散型分布、連続型分布、同時分布、周辺分布、条件付き分布、独立性、期待値・分散、積率母関数、変数変換、正規分布から派生する分布まで扱っています。

2章演習で証明が出る式は、本文の分布定義や変数変換公式に戻るとほぼ処理できます。特に「確率の総和は1」「二項係数の変形」「ヤコビアン」「ガンマ積分」が頻出の芯です。

2.1 離散型の確率分布

離散一様分布

値 $1, 2, \dots, n$ をすべて同じ確率で取る分布です。

$$\begin{aligned}P(X=x) &= 1/n, \quad x=1, 2, \dots, n \\E[X] &= (n+1)/2 \\Var(X) &= (n^2-1)/12\end{aligned}$$

具体例：サイコロなら $n=6$ で $E[X]=3.5$ 、分散は $35/12$ です。どの目も同じ確率という「基準モデル」です。

注意：

一様分布は「値が同じくらい出る」という仮定です。現実のデータが偏っていれば、一様分布を置くのは不自然です。

ベルヌーイ分布

成功を1、失敗を0で表す分布です。

$$\begin{aligned}P(X=x) &= p^x(1-p)^{1-x}, \quad x=0, 1 \\E[X] &= p \\Var(X) &= p(1-p) \\G(s) &= E[s^X] = (1-p) + ps\end{aligned}$$

具体例：コインで表を成功とし、表の確率が0.6なら $X \sim \text{Bernoulli}(0.6)$ で、平均は0.6です。

二項分布

独立なベルヌーイ試行を n 回足した分布です。

$$\begin{aligned}X &= X_1 + \dots + X_n, \quad X_i \sim \text{Bernoulli}(p) \\P(X=x) &= C(n, x) p^x (1-p)^{n-x} \\E[X] &= np \\Var(X) &= np(1-p) \\G(s) &= (1-p + ps)^n\end{aligned}$$

具体例：成功確率0.2の作業を10回行うとき、成功回数は $B(10, 0.2)$ 。平均は2回、分散は1.6です。

演習での使い方： $E[X(X-1)]$ を使うと分散の証明が短くなります。

ポアソン分布

一定時間・一定領域内に起きる回数のモデルです。

$$\begin{aligned}P(X=x) &= \exp(-\lambda) \lambda^x / x!, \quad x=0, 1, 2, \dots \\E[X] &= \lambda \\Var(X) &= \lambda \\G(s) &= \exp(\lambda(s-1))\end{aligned}$$

具体例：1時間あたり平均3件の問い合わせが来るなら、1時間の件数を $\text{Poisson}(3)$ と近似できます。

二項分布との関係：

$$\begin{aligned}&B(n, p) \text{ で } n \text{ が大きく } p \text{ が小さく } np = \lambda \text{ が一定} \\&\rightarrow \text{Poisson}(\lambda)\end{aligned}$$

これは「まれな事象がたくさんのおきで起きる」状況です。

超幾何分布

有限母集団から非復元抽出するときの成功数の分布です。

$$\begin{aligned}P(X=x) &= \frac{C(M, x) C(N-M, n-x)}{C(N, n)} \\E[X] &= nM/N \\Var(X) &= n(M/N)(1-M/N)((N-n)/(N-1))\end{aligned}$$

具体例：100個中20個が不良品で、10個を戻さず抽出するときの不良品数です。二項分布と違い、1回取ると成功確率が変わります。

幾何分布

初めて成功するまでの失敗回数、または成功までの試行回数を表します。本文では「成功までの失敗回数」型が見えています。

$$\begin{aligned}P(X=x) &= p(1-p)^x, \quad x=0, 1, 2, \dots \\E[X] &= (1-p)/p \\Var(X) &= (1-p)/p^2\end{aligned}$$

具体例：成功確率0.25で、初成功前の失敗回数の平均は3回です。

負の二項分布

r回成功するまでの失敗回数の分布です。幾何分布をr個足したものとして見られます。

$$\begin{aligned}P(X=x) &= C(r+x-1, x) p^r (1-p)^x \\E[X] &= r(1-p)/p \\Var(X) &= r(1-p)/p^2\end{aligned}$$

具体例：成功確率0.5で3回成功するまでの失敗回数の平均は3です。

2.2 連続型の確率分布

連続一様分布

区間 [a, b] のどこでも同じ密度を持つ分布です。

$$\begin{aligned}f(x) &= 1/(b-a), \quad a \leq x \leq b \\E[X] &= (a+b)/2 \\Var(X) &= (b-a)^2/12\end{aligned}$$

具体例：0分から10分の間でランダムに待ち時間が決まるなら、平均は5分です。

正規分布

平均 μ 、分散 σ^2 の釣鐘型の分布です。

$$\begin{aligned}f(x) &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\} \\X &\sim N(\mu, \sigma^2)\end{aligned}$$

標準化：

$$Z = (X - \mu) / \sigma \sim N(0, 1)$$

具体例：テスト点が平均60、標準偏差10なら、80点は $Z=2$ です。標準正規表で上側確率を読めます。

対数正規分布

$\log X$ が正規分布に従うとき、 X は対数正規分布です。正の値だけを取り、右に長い裾を持ちます。

具体例：所得や株価のように、倍率的に増減する量に使われます。

指数分布

次に事象が起こるまでの待ち時間のモデルです。

$$\begin{aligned}f(x) &= \lambda \exp(-\lambda x), \quad x \geq 0 \\E[X] &= 1/\lambda \\Var(X) &= 1/\lambda^2\end{aligned}$$

具体例：平均待ち時間が5分なら $\lambda=1/5$ です。

ガンマ分布

指数分布の和を一般化した分布です。率パラメータ β の形では

$$f(x; \alpha, \beta) = \beta^\alpha / \Gamma(\alpha) x^{\alpha-1} \exp(-\beta x), x > 0$$
$$E[X] = \alpha / \beta$$
$$\text{Var}(X) = \alpha / \beta^2$$

具体例：1件の到着待ちが指数分布なら、3件目までの待ち時間はガンマ分布になります。

再生性：

$$X \sim \text{Ga}(\alpha_1, \beta), Y \sim \text{Ga}(\alpha_2, \beta), \text{独立}$$
$$\rightarrow X+Y \sim \text{Ga}(\alpha_1+\alpha_2, \beta)$$

演習2.4のような比の問題では、和と比に変数変換し、ヤコビアンを掛けます。

ベータ分布

0から1の範囲の割合を表す分布です。

$$f(x) = \Gamma(\alpha+\beta) / (\Gamma(\alpha)\Gamma(\beta)) x^{\alpha-1}(1-x)^{\beta-1}$$

具体例：成功確率 p そのものを確率変数として扱うときに使われます。ガンマ分布の比とも関係します。

カイ二乗分布・t分布・F分布

標準正規から作られる重要分布です。

$$Z_1, \dots, Z_\nu \text{ 独立 } N(0, 1)$$
$$\rightarrow Z_1^2 + \dots + Z_\nu^2 \sim \chi^2_\nu$$

$$T = Z / \sqrt{U/\nu}, Z \sim N(0, 1), U \sim \chi^2_\nu$$
$$\rightarrow T \sim t_\nu$$

$$F = (U_1/\nu_1) / (U_2/\nu_2)$$
$$\rightarrow F \sim F(\nu_1, \nu_2)$$

具体例：母分散未知の平均の信頼区間はt分布、分散の信頼区間はカイ二乗分布、2つの分散比の検定はF分布を使います。

2.3 同時分布・周辺分布・条件付き分布

同時確率と周辺確率

2変数 X, Y を同時に見るとき、離散型なら同時確率関数 $p(x, y)$ 、連続型なら同時密度 $f(x, y)$ を使います。

離散: $P(X=x, Y=y)=p(x, y)$

連続: $P((X, Y) \in A) = \int \int_A f(x, y) \, dx dy$

周辺分布は、見ない変数を足す・積分して消します。

離散: $p_X(x) = \sum_y p(x, y)$

連続: $f_X(x) = \int f(x, y) \, dy$

具体例: 学生の「数学点 X 」と「英語点 Y 」の同時分布から、数学点だけの分布を知りたいなら Y について合計します。

条件付き分布

ある値がわかった後の分布です。

離散: $P(X=x \mid Y=y) = p(x, y) / p_Y(y)$

連続: $f_{X|Y}(x|y) = f(x, y) / f_Y(y)$

具体例: 全体の数学点分布ではなく、「英語が80点の人」に限った数学点分布を見るのが条件付き分布です。

独立性

同時分布が周辺分布の積に分解できると独立です。

離散: $p(x, y) = p_X(x)p_Y(y)$

連続: $f(x, y) = f_X(x)f_Y(y)$

注意: 無相関 $\text{Cov}(X, Y) = 0$ は独立より弱い条件です。正規分布の特別な場合を除き、無相関だから独立とは言えません。

共分散と相関係数

$\text{Cov}(X, Y) = E[(X - E[X])(Y - E[Y])]$
 $= E[XY] - E[X]E[Y]$

$\rho = \text{Cov}(X, Y) / (\sqrt{\text{Var}(X)}\sqrt{\text{Var}(Y)})$

具体例: 勉強時間 X と点数 Y の相関が正なら、勉強時間が長いほど点数も高い傾向です。ただし因果関係は別問題です。

2.4 変数変換

1変数の変換

$Y = g(X)$ が単調変換なら、密度は

$f_Y(y) = f_X(g^{-1}(y)) \, |dg^{-1}(y)/dy|$

です。最後の絶対値は、変数の目盛りが伸び縮みする分を補正します。

具体例: $Y = 2X$ なら $X = Y/2$ 、 $dx/dy = 1/2$ なので密度は半分になります。

2変数以上の変換

多変数ではヤコビアンを使います。

$f_{\{U, V\}}(u, v) = f_{\{X, Y\}}(x(u, v), y(u, v)) \, |J|$

ここで

$J = \det \partial(x, y) / \partial(u, v)$

です。

演習2.4では、 x_1, x_2, x_3 を u, v, s に変換して、ヤコビアン $s^2(1-u)$ が出ます。これを忘れると密度が正規化されません。

2.5 積率母関数・確率母関数

積率母関数

$$M(t) = E[\exp(tX)]$$

微分して $t=0$ を代入するとモーメントが得られます。

$$M'(0) = E[X]$$

$$M''(0) = E[X^2]$$

また、独立な和では積になります。

$$X, Y \text{ 独立} \rightarrow M_{\{X+Y\}}(t) = M_X(t)M_Y(t)$$

具体例：独立な正規分布の和が正規分布になることは、積率母関数で確認できます。

確率母関数

非負整数値の確率変数では

$$G(s) = E[s^X]$$

を使います。二項分布やポアソン分布の和を扱うときに便利です。

2.6 章の横断的な注意

- ・「確率関数」と「確率密度」は違います。連続型では一点の確率は0で、区間の面積が確率です。
- ・分布のパラメータ表記は本によって違います。ガンマ分布は尺度パラメータか率パラメータかを必ず確認します。
- ・和の分布を出すときは、独立性が前提になっていることが多いです。
- ・変数変換では、逆変換の範囲とヤコビアンを必ず書きます。

ミニ確認問題

1. $X \sim B(10, 0.3)$ の平均と分散を求めよう。
2. $X \sim \text{Poisson}(4)$ なら $P(X=2)$ はどう書けるか。
3. $X \sim N(50, 10^2)$ で $X=70$ の標準化値を求めよう。
4. 同時密度から周辺密度を求めるとき、なぜ片方の変数で積分するのか説明しよう。

参考リンク

- ・確率分布の基礎: <https://hosho.ees.hokudai.ac.jp/tsuyu/top/dct/stat.html>
- ・確率母関数: <https://stats.biopapyrus.jp/probability/pgf.html>
- ・ガンマ分布と関連分布: <https://bellcurve.jp/statistics/course/6981.html>