

統計学6章演習 解説ノート

今日のテーマ

6章は、データ解析の結果を読んで説明する章です。主役は「重回帰分析」「主成分分析」「単回帰の手計算」「ポアソン分布の適合度検定」です。

問6.1 重回帰分析の結果を読む

(1) 重回帰モデルの通常の仮定

モデルは

$$Y_i = \beta + \beta_1 x_{1i} + \beta_2 x_{2i} + \varepsilon_i$$

です。通常は次の仮定を置きます。

- ・誤差の平均は0: $E[\varepsilon_i]=0$
- ・誤差の分散は一定: $\text{Var}(\varepsilon_i)=\sigma^2$
- ・誤差どうしは独立: $\text{Cov}(\varepsilon_i, \varepsilon_j)=0$
- ・検定を正確に行うため、誤差は正規分布に従うと仮定することが多い
- ・説明変数の間に完全な線形関係がない

最後の条件は特に大切です。説明変数が完全に重なると、それぞれの係数を一意に決められません。

(2) Listening と Reading による重回帰

推定された回帰式は、おおよそ

$$\text{Score} = -1.938 + 0.099 \text{ Listening} + 0.194 \text{ Reading}$$

です。

重相関係数は 0.793、決定係数は 0.629、自由度調整済み決定係数は 0.523 です。これは、Listening と Reading を一緒に使くと、Score のばらつきの約63%を説明できる、という意味です。

分散分析表では $F = 5.926$ 、 $P = 0.031$ です。5%有意水準なら、モデル全体としては「Score と説明変数の間に関係がある」と判断できます。

一方、係数ごとの検定では

- ・Listening: 係数 0.099、P値 0.457
- ・Reading: 係数 0.194、P値 0.141

となり、どちらも単独では5%水準で有意とはいえません。これは「モデル全体は効いているが、2変数を同時に入れると個別の効果ははっきりしない」という状況です。Listening と Reading が互いに相関しているため、効果を分けにくくなっていると考えられます。

(3) 1変数だけを使った単回帰との比較

単回帰の結果は次のように読めます。

Listeningのみ: 係数 0.254, P値 0.026, 決定係数 0.483, 調整済み 0.418
Readingのみ: 係数 0.262, P値 0.009, 決定係数 0.596, 調整済み 0.545
Totalのみ: 係数 0.148, P値 0.007, 決定係数 0.619, 調整済み 0.572

単独で見ると、Reading や Total は Score とかなり強く関係しているように見えます。Total は Listening と Reading の合計なので、2つの情報をまとめて持っており、単回帰では最も説明力が高くなっています。

ただし、Total は Listening と Reading の合計です。そのため、Total を入れると「Listening と Reading を別々に入れた重回帰」とは違い、2つを合わせた総合力を見ていることになります。

(4) Listening, Reading, Total を同時に入れられるか

同時には入れられません。理由は

$$\text{Total} = \text{Listening} + \text{Reading}$$

という完全な線形関係があるからです。これは完全な多重共線性です。この場合、回帰係数の組み合わせが一意に決まらないため、通常重回帰分析は実行できません。

問6.2 主成分分析と因子分析

(1) 記述統計・相関・主成分分析・因子分析をやさしく説明

記述統計は、平均・標準偏差・相関係数などでデータの特徴を短く要約する方法です。

主成分分析は、複数の科目の点数を、少数の新しい軸にまとめる方法です。今回なら、第1主成分はどの科目にも正の重みがあるため「総合学力」と読むのが自然です。

因子分析は、観測された点数の背後にある見えない要因を考える方法です。たとえば「文系力」「理系力」のような潜在的な力が点数に表れている、と考えます。

(2) 主成分分析と因子分析の違い

主成分分析は、データのばらつきをできるだけ失わずに圧縮する方法です。目的は「要約」です。

因子分析は、観測変数の背後にある共通因子を推定する方法です。目的は「背後の構造の説明」です。

同じような表や負荷量が出てきますが、主成分分析は合成得点を作る方法、因子分析は潜在因子を仮定する方法、と分けて考えると整理しやすいです。

(3) 主成分分析の結果の読み方

固有値は

第1主成分 3.030, 第2主成分 1.219, 第3主成分 0.431, 第4主成分 0.178, 第5主成分 0.143

です。寄与率は

第1主成分 60.6%
第2主成分 24.4%
累積で第2主成分まで 85.0%

なので、第1・第2主成分まで見れば、全体の情報のかなり大きな部分を説明できます。

第1主成分の固有ベクトルは全科目で正です。したがって「全科目に共通する総合力」と解釈できます。

第2主成分は、国語・社会が正、数学・理科が負です。したがって「文系科目と理系科目の対比」と読むのが自然です。

(4) 因子負荷量の見方

第1因子の負荷量は、国語・社会・数学・理科・英語のすべてで大きく正です。これは第1因子が「全体的な学力」を表すことを示します。

第2因子は、国語・社会が正、数学・理科が負です。英語は小さめです。したがって「文系寄りか理系寄りか」を表す軸として読めます。

バイプロットを描くなら、横軸を第1因子、縦軸を第2因子にして、国語・社会は右上、数学・理科は右下、英語は右寄り、縦方向は中間あたりに置きます。

問6.3 単回帰の手計算

与えられた値

$x = 0, 1, 2, 3, 4$ で、平均は $\bar{x} = 2.0$ 、偏差平方和は

$$A_x = \sum (x_i - \bar{x})^2 = 10.0$$

です。3つの目的変数について、平均・偏差平方和・偏差積和は次の通りです。

$$y(1): \text{平均 } 1.1, A_y = 3.7, A_{xy} = 5.0$$

$$y(2): \text{平均 } 2.1, A_y = 11.2, A_{xy} = 10.0$$

$$y(3): \text{平均 } 4.1, A_y = 41.2, A_{xy} = 20.0$$

(1) 回帰直線

単回帰では

$$b = A_{xy} / A_x$$

$$a = \bar{y} - b \bar{x}$$

です。したがって

$$y(1): b=0.5, a=0.1 \text{ したがって } \hat{y} = 0.1 + 0.5x$$

$$y(2): b=1.0, a=0.1 \text{ したがって } \hat{y} = 0.1 + 1.0x$$

$$y(3): b=2.0, a=0.1 \text{ したがって } \hat{y} = 0.1 + 2.0x$$

3本とも切片は同じで、傾きだけが大きくなっています。

(2) 散布図の読み方

3つのデータはどれも右上がりです。 $y(3)$ は傾きが大きいので、 x が増えると y が大きく増えます。ただし、回帰直線からのずれの大きさは3つとも同程度になるように作られています。

(3) 決定係数・寄与率・残差平方和

決定係数は

$$R^2 = A_{xy}^2 / (A_x A_y)$$

です。

$$y(1): R^2 = 25/37 \approx 0.676$$

$$y(2): R^2 = 100/112 \approx 0.893$$

$$y(3): R^2 = 400/412 \approx 0.971$$

x との直線関係は $y(3)$ が最も強く、次に $y(2)$ 、最後に $y(1)$ です。

回帰によって説明される平方和は $SSR = R^2 A_y$ 、残差平方和は $SSE = A_y - SSR$ です。3つとも

$$SSE = 1.2$$

になります。残差分散の不偏推定値は、自由度 $5-2=3$ で割るので

$$s^2 = 1.2/3 = 0.4$$

です。

(4) 予測の不確かさ

回帰直線のまわりのばらつきは、3つとも $s^2=0.4$

です。つまり、傾きや相関の強さは違っても、直線からの縦方向のずれの大きさは同じです。

(5) $y(2)$ の条件付き期待値の95%信頼区間

$y(2)$ の回帰直線は

$$m_0 = 0.1 + x_0$$

です。 x が x_0 のときの平均的な y の95%信頼区間は

$$m_0 \pm t_{0.025(3)} s \sqrt{1/n + (x_0 - \bar{x})^2 / A_x}$$

ここで $n=5$, $\bar{x}=2$, $A_x=10$, $s=\sqrt{0.4}$ 、 $t_{0.025(3)} \approx 3.182$ です。

個人1人の予測区間を出すときは、平方根の中にさらに 1 を足します。平均の信頼区間より予測区間の方が広がります。

問6.4 ポアソン分布の最尤推定と適合度検定

問題の整理

96試合のゴール数データです。ゴール数の合計は

$$t = 101$$

なので、標本平均は

$$\bar{x} = 101/96 \approx 1.052$$

です。

(1) ポアソン分布と考えられる理由

ゴール数は非負の整数です。一定時間内に起こる回数を数えているので、まずはポアソン分布を候補にできます。ただし、実際のサッカーではチーム力・対戦相手・ホーム/アウェイなどで得点率が変わるため、完全に同じポアソン分布とみなせるかは検定で確認します。

(2) λ の最尤推定量

ポアソン分布では、最尤推定量は標本平均です。

$$\hat{\lambda} = \bar{x} = 101/96 \approx 1.052$$

このデータでは、1試合あたり平均約1.05ゴールと推定されます。

(3) 適合度検定

期待度数が5以下になる階級はまとめます。階級をまとめた上で、カイ二乗統計量は

$$\chi^2 \approx 0.774$$

となり、P値は

$$P \approx 0.856$$

です。P値が大きいので、「このデータはポアソン分布に従う」という帰無仮説を棄却しません。

大事なのは「ポアソン分布であると証明された」ではなく、「このデータからはポアソン分布と矛盾するとまではいえない」という読み方です。

(4) λ の95%信頼区間

ワルド型の近似では

$$\begin{aligned} & \hat{\lambda} \pm 1.96 \sqrt{\hat{\lambda}/n} \\ &= 1.052 \pm 0.205 \\ &= (0.847, 1.257) \end{aligned}$$

です。

スコア型の近似を使うと

$$1.073 \pm 0.210 = (0.863, 1.283)$$

となります。どちらも、 λ はおおよそ0.85から1.28の範囲にありそうだ、という解釈です。

よくあるつまずき

- ・重回帰で「モデル全体は有意」でも「各係数が有意」とは限りません。説明変数どうしの相関があると、個別の効果を分けにくくなります。
- ・主成分分析の第1主成分は、固有ベクトルの符号を見て解釈します。すべて正なら総合力と読みやすいです。
- ・適合度検定では期待度数が小さい階級をまとめます。小さい階級をそのまま使うとカイ二乗近似が不安定になります。

確認問題

1. Total を Listening と Reading と同時に重回帰へ入れると、なぜ係数が一意に決まらないのでしょうか。
2. 主成分分析で「第1主成分の寄与率60.6%」とは、何の60.6%を説明しているという意味でしょうか。
3. ポアソン適合度検定でP値が0.856だったとき、「ポアソン分布である」と断言してよいでしょうか。

参考リンク

- ・重回帰分析・決定係数の考え方: <https://plaza.umin.ac.jp/~health-stat/faq/faq19/>
- ・主成分分析の固有値・寄与率の考え方: <https://www.math.chuo-u.ac.jp/~sugiyama/tokeior.pdf>
- ・適合度検定と自由度の考え方: <https://herolog.jp/statistics/goodness-of-fit-test.php>