

統計学6章 本文網羅ノート

章全体の見取り図

6章は「多変量データをどう要約し、説明し、分類するか」の章です。写真で確認できた範囲では、回帰分析、重回帰、変数選択、主成分分析、因子分析、クラスター分析、判別分析、ロジスティック回帰、対応分析に近い図表の読み方で扱っています。

6章は公式暗記よりも、出力表を読めることが大事です。係数、標準誤差、t値、P値、決定係数、固有値、寄与率、因子負荷量、デンドログラムなど、表や図が何を意味するかを押さえます。

6.1 単回帰分析

モデル

$$y_i = a + b x_i + \varepsilon_i$$

x が説明変数、 y が目的変数、 ε が誤差です。

最小二乗法では

$$\sum (y_i - a - bx_i)^2$$

を最小にします。

推定式:

$$b = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$a = \bar{y} - b \bar{x}$$

具体例: 勉強時間 x と点数 y なら、 b は「勉強時間が1時間増えると点数が平均何点増えるか」を表します。

相関と回帰の違い

相関は対称です。 x と y の関連の強さを見ます。回帰は非対称で、 x から y を予測します。

注意: 相関が高くても因果関係とは限りません。

6.2 決定係数と回帰の検定

決定係数は、 y の全体のばらつきのうち回帰式で説明できた割合です。

$$R^2 = 1 - \text{残差平方和} / \text{全平方和}$$

具体例: $R^2 = 0.64$ なら、 y のばらつきの64%を回帰式で説明できたという意味です。

係数の検定:

$$H_0: b=0$$

をt検定します。P値が小さければ、 x は y の説明に役立つと判断します。

6.3 重回帰分析

モデル

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi} + \varepsilon_i$$

β_j は「他の変数を固定したとき、 x_j が1増える効果」です。

具体例: 期末点をListeningとReadingで説明するとき、Listeningの係数は「Readingが同じ学生同士で比べたListeningの効果」です。

回帰出力の読み方

- ・ 係数: 効果の向きと大きさ。
- ・ 標準誤差: 係数推定の不確かさ。
- ・ t値: 係数/標準誤差。

- ・ P値: 係数が0という仮説への反証の強さ。
- ・ F値: モデル全体が役に立つか。
- ・ 自由度調整済み決定係数: 説明変数の数を考慮した説明率。

多重共線性

説明変数同士が強く関係すると、個別係数が不安定になります。完全な関係があると推定できません。

Total = Listening + Reading

なら3つを同時に入れることはできません。

具体例: 身長cmと身長mを同時に説明変数に入れるのは、同じ情報を二重に入れているようなものです。

6.4 変数選択

重回帰では、説明変数を増やせば見かけの R^2 は上がりやすいです。そのため、不要な変数を入れすぎない判断が必要です。

代表的な基準:

- ・ P値: 有意でない変数を外す。
- ・ 自由度調整済み R^2 : 変数数のペナルティを考慮。
- ・ AIC: 当てはまりとモデルの複雑さのバランス。

具体例:

期末点を予測するのに、Listening、Reading、Totalを全部入れるより、Totalだけの方が単純で安定する場合があります。

6.5 主成分分析

目的

多くの変数を、少数の合成変数にまとめます。第1主成分は、データの分散が最大になる方向です。

標準化した変数から作る主成分:

$$Z_k = a_{1X_1} + a_{2X_2} + \dots + a_{pX_p}$$

係数ベクトルは相関行列の固有ベクトル、主成分の分散は固有値です。

固有値・寄与率・累積寄与率

$$\text{寄与率} = \text{固有値} / \text{固有値の合計}$$

累積寄与率は、複数の主成分でどれだけ情報を説明したかを表します。

具体例: 5科目の標準化データで第1主成分の寄与率が60%なら、「5科目全体のばらつきの60%を1本の総合得点で説明できる」という意味です。

主成分負荷量

主成分と元の変数の関係を表します。すべての科目で第1主成分負荷量が正なら「総合力」と解釈できます。国語・社会が正、数学・理科が負なら「文系対理系」の軸と読めます。

注意: 主成分の符号は全体を反転しても意味は同じです。プラス・マイナスそのものより、同じ向きか逆向きかを見ます。

6.6 因子分析

目的

観測変数の背後にある、直接見えない共通因子を考えます。

主成分分析との違い:

- ・主成分分析: 情報を圧縮する。
- ・因子分析: 背後の潜在構造を説明する。

因子負荷量

因子と各変数の関係の強さです。大きな負荷量を持つ変数を見て、因子に名前を付けます。

具体例: 国語・英語・社会の負荷量が高い因子は「文系能力」、数学・理科が高い因子は「理系能力」と解釈できます。

回転

因子を解釈しやすくするため、軸を回転します。バリマックス回転などが使われます。

注意: 因子名は自動で決まるわけではありません。負荷量表を見て人間が解釈します。

6.7 クラスター分析

目的

似ている観測対象をグループに分ける方法です。

距離の例:

$$\text{ユークリッド距離} = \sqrt{\sum (x_i - y_i)^2}$$

階層的クラスター分析では、デンドログラムを見ます。

- ・最短距離法: 群間の最も近い点を見る。
- ・最長距離法: 群間の最も遠い点を見る。
- ・群平均法: 群間距離の平均を見る。
- ・ワード法: 群内平方和の増加が小さいようにまとめる。

具体例:

5科目の点数パターンが似ている学生をグループ分けできます。総合的に高い群、文系が高い群、理系が高い群などです。

注意: 変数の単位が違くと距離が一部の変数に支配されるので、標準化が重要です。

6.8 判別分析

目的

既にグループがわかっているデータから、新しいデータの所属グループを予測します。

線形判別では

$$z = a_1x_1 + \dots + a_px_p$$

のような判別得点を作ります。

具体例: 過去の可否データから、模試点・内申点を使って合格/不合格を判別するモデルを作るイメージです。

注意:

判別分析はグループの分散共分散構造に仮定を置きます。仮定が合わない場合はロジスティック回帰なども検討します。

6.9 ロジスティック回帰

目的変数が0/1のときに使います。確率 p を直接線形回帰するのではなく、オッズの対数を線形モデルにします。

$$\log(p/(1-p)) = \beta_0 + \beta_1x_1 + \dots + \beta_px_p$$

具体例: 購入する/しない、合格する/しない、病気あり/なしのような二値データです。

係数 β の指数 $\exp(\beta)$ はオッズ比として解釈できます。

6.10 図表の読み方

散布図

直線関係、外れ値、非線形関係を確認します。回帰をする前に必ず見たい図です。

バイプロット

主成分分析で、観測対象と変数を同じ平面に表示します。近い点は似ていて、矢印の向きは変数の関係を示します。

デンドログラム

クラスター分析で、どの対象がどの順に結合されたかを示します。切る高さでクラスター数が変わります。

6章のよくあるミス

- ・ P値だけでモデルの良し悪しを決める。
- ・ 決定係数が高いから因果関係があると思う。
- ・ 重回帰係数を「単純な相関」と同じように読む。
- ・ 主成分分析と因子分析を同じものとして扱う。
- ・ 標準化せずに距離ベースの分析をして、単位の大きい変数に引っ張られる。

ミニ確認問題

1. 回帰係数 β_1 は、単回帰と重回帰で解釈がどう変わるか。
2. 自由度調整済み R^2 を見る理由を説明しよう。
3. 主成分分析の第1主成分と因子分析の第1因子は何が違うか。
4. クラスター分析で標準化が必要になるのはどんな場合か。

参考リンク

- ・ 決定係数と回帰: <https://plaza.umin.ac.jp/~health-stat/faq/faq19/>
- ・ 回帰分析の基礎: <https://www2.kobe-u.ac.jp/~bunji/files/lecture/stat/stat-04-regression.pdf>
- ・ 主成分分析: <https://www.math.chuo-u.ac.jp/~sugiyama/tokeior.pdf>