

統計学6章 多変量解析の要点PDF

今日のテーマ

6章は、多変量データをまとめて見る章です。写真では、単回帰、重回帰、主成分分析、因子分析、クラスター分析、判別分析などが確認できました。このPDFでは、試験や演習で使いやすい形に整理します。

1. 単回帰分析

単回帰は、1つの説明変数 x で目的変数 y を説明する方法です。

$$y_i = a + b x_i + \varepsilon_i$$

最小二乗法では、残差平方和

$$\sum (y_i - a - b x_i)^2$$

を最小にします。

傾きと切片は

$$b = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$
$$a = \bar{y} - b \bar{x}$$

です。傾き b は「 x が1増えると、 y が平均的にどれだけ変わるか」を表します。

2. 決定係数

決定係数は、 y のばらつきのうち回帰式で説明できた割合です。

$$R^2 = 1 - \frac{\text{残差平方和}}{\text{全平方和}}$$

0から1の値を取り、1に近いほど直線によく説明できます。ただし、説明変数を増やすと R^2 は下がりにくいので、重回帰では自由度調整済み決定係数も見ます。

3. 重回帰分析

説明変数が複数あるときは

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \varepsilon_i$$

と書きます。

重回帰でよく見る表は3つです。

- ・ 係数：他の変数を固定したとき、その変数が y に与える影響。
- ・ t 値・ P 値：各係数が0といえるかを検定する。
- ・ F 値・ P 値：モデル全体として説明力があるかを検定する。

注意点は多重共線性です。たとえば

$$\text{Total} = \text{Listening} + \text{Reading}$$

のような完全な関係があると、3つを同時に説明変数に入れることはできません。係数が一意に決まらないからです。

4. 主成分分析

主成分分析は、多くの変数を少数の合成変数にまとめる方法です。第1主成分は、データの分散が最も大きくなる方向です。

標準化した変数を使うとき、第 k 主成分は

$$Z_k = a_1 X_1 + a_2 X_2 + \dots + a_p X_p$$

の形です。係数ベクトルは相関行列の固有ベクトル、主成分の分散は固有値になります。

寄与率は

第k主成分の固有値 / 固有値の合計

です。たとえば第1主成分の寄与率が60%なら、標準化された全体のばらつきの60%を第1主成分が説明している、という意味です。

5. 因子分析

因子分析は、観測された変数の背後にある見えない因子を仮定する方法です。主成分分析が「要約」なのに対して、因子分析は「背後の構造の説明」です。

因子負荷量は、各変数と因子の関係の強さを表します。負荷量が大きい変数を見て、その因子に名前をつけます。たとえば国語・社会が大きければ「文系力」、数学・理科が大きければ「理系力」と解釈できます。

6. クラスター分析

クラスター分析は、似ている観測値をグループに分ける方法です。

距離の定義と結合方法が重要です。

- ・ユークリッド距離：点同士の通常の距離。
- ・最短距離法：2群の中で最も近い点同士の距離を見る。
- ・最長距離法：2群の中で最も遠い点同士の距離を見る。
- ・ワード法：群内平方和の増加が小さいようにまとめる。

結果はデンドログラムで表され、どの高さで切るかによってクラスター数が変わります。

7. 判別分析

判別分析は、すでにグループがわかっているデータから、新しいデータがどのグループに属するかを判定する方法です。

線形判別では、変数の線形結合

$$z = a_1x_1 + a_2x_2 + \dots + a_px_p$$

でグループを分けます。ロジスティック回帰も、分類問題でよく使われます。

よくあるつまずき

- ・相関が高くても因果関係があるとは限りません。
- ・回帰係数は「他の説明変数を固定したとき」の効果です。
- ・主成分分析の符号は反転しても意味は同じです。大事なのは、どの変数が同じ向きに大きいからです。
- ・因子分析の因子名は自動で決まるものではなく、負荷量を見て人間が解釈します。

確認問題

1. 単回帰の傾きbは何を意味するか説明しよう。
2. 重回帰で、モデル全体のP値は有意なのに個別係数が有意でない場合、何が起きている可能性がありますか。
3. 主成分分析と因子分析の目的の違いを一文で説明しよう。

参考リンク

- ・ 決定係数・自由度調整済み決定係数: <https://plaza.umin.ac.jp/~health-stat/faq/faq19/>
- ・ 回帰分析の基礎: <https://www2.kobe-u.ac.jp/~bunji/files/lecture/stat/stat-04-regression.pdf>
- ・ 主成分分析の固有値・寄与率: <https://www.math.chuo-u.ac.jp/~sugiyama/tokeior.pdf>